



PENERAPAN METODE *HYBRID* GARCH-LSTM UNTUK MERAMALKAN HARGA BAWANG PUTIH NASIONAL

AKMAL RIZA WIBISONO



DEPARTEMEN STATISTIKA FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM INSTITUT PERTANIAN BOGOR BOGOR 2024





- Hak Cipta Dilindungi Undang-undang

 1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
 2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

IPB University



PERNYATAAN MENGENAI SKRIPSI DAN SUMBER INFORMASI SERTA PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa skripsi dengan judul "Penerapan Metode Hybrid GARCH-LSTM untuk Meramalkan Harga Bawang Putih Nasional" adalah karya saya dengan arahan dari dosen pembimbing dan belum diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka di bagian akhir skripsi ini.

Dengan ini saya melimpahkan hak cipta dari karya tulis saya kepada Institut Pertanian Bogor.

Bogor, Juli 2024

Akmal Riza Wibisono G1401201086



ABSTRAK

AKMAL RIZA WIBISONO. Penerapan Metode Hybrid GARCH-LSTM untuk Meramalkan Harga Bawang Putih Nasional. Dibimbing oleh ITASIA DINA SULVIANTI dan AKBAR RIZKI.

Analisis deret waktu digunakan untuk menghasilkan ramalan terhadap kejadian yang akan datang dengan mengasumsikan data dalam kondisi stasioner dan linear. Namun, dalam kehidupan nyata, data sering kali bersifat nonstasioner, nonlinear, dan memiliki volatilitas tinggi. Untuk mengatasi permasalahan tersebut, penelitian ini mengombinasikan metode statistika klasik dan metode deep learning, yaitu Generalized Autoregressive Conditional Heteroskedasticity (GARCH) dengan Long Short-Term Memory (LSTM), sebagai model hybrid GARCH-LSTM. Metode ini dapat mempertahankan kemampuan model GARCH menginterpretasikan kondisi fluktuatif dan sekaligus meningkatkan akurasi ramalan dengan memodelkan sisaannya menggunakan model LSTM. Penelitian ini menggunakan data harian harga bawang putih nasional sejak Juli 2021 hingga Februari 2024 yang diperoleh dari website Badan Pangan Nasional. Model GARCH terbaik untuk memodelkan harga bawang putih nasional adalah model GARCH(1,1) dengan nilai MAPE sebesar 9,73%. Sisaan dari model GARCH(1,1) dimodelkan menggunakan model LSTM dengan skenario learning rate sebesar 0,005 dan batch size sebesar 16 yang diperoleh melalui langkah hyperparameter tuning menggunakan metode time series k-fold cross validation. Model hybrid GARCH-LSTM pada data harga bawang putih nasional menghasilkan ramalan yang sangat akurat dengan nilai MAPE sebesar 3,84%. Hasil ramalan harga bawang putih nasional menggunakan model hybrid GARCH-LSTM menunjukkan tren kenaikan yang disertai fluktuasi harga hingga menyentuh kisaran Rp45.000/kg pada akhir Juni 2024.

Kata kunci: GARCH, harga bawang putih, LSTM, hybrid GARCH-LSTM,

volatilitas

ABSTRACT

AKMAL RIZA WIBISONO. Application of the Hybrid GARCH-LSTM Method for Forecasting National Garlic Prices. Supervised by ITASIA DINA SULVIANTI and AKBAR RIZKI.

Time series analysis is employed to generate forecasts for future events assuming data are stationary and linear. However, in real-life scenarios, data are often nonstationary, nonlinear, and highly volatile. To address these challenges, this research combines classical statistics with deep learning, specifically Generalized Autoregressive Conditional Heteroskedasticity (GARCH) and Long Short-Term Memory (LSTM), termed as hybrid GARCH-LSTM model. This method can maintain the GARCH model's ability to interpret fluctuating conditions while simultaneously improving forecasting accuracy by modeling the residuals using the LSTM model. The research uses national garlic price data from July 2021 to February 2024 sourced from the National Food Agency website. The optimal GARCH model obtained for modeling national garlic price is the GARCH(1,1) model achieving a MAPE of 9.73%. The residuals of the GARCH(1,1) model are modeled using LSTM with a learning rate scenario of 0.005 and a batch size of 16, determined through hyperparameter tuning using time series k-fold cross-validation. The hybrid GARCH-LSTM model applied to national garlic price data produces highly accurate forecasts, achieving a MAPE of 3.84%. The forecast of national garlic prices using this hybrid GARCH-LSTM model indicate an upward trend accompanied by price fluctuations, reaching approximately Rp45,000/kg by the end of June 2024.

GARCH, garlic price, hybrid GARCH-LSTM, LSTM, volatility. Keywords:



© Hak Cipta milik IPB, tahun 2024 Hak Cipta dilindungi Undang-Undang

Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan atau menyebutkan sumbernya. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik, atau tinjauan suatu masalah, dan pengutipan tersebut tidak merugikan kepentingan IPB.

Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apa pun tanpa izin IPB.





PENERAPAN METODE *HYBRID* GARCH-LSTM UNTUK MERAMALKAN HARGA BAWANG PUTIH NASIONAL

AKMAL RIZA WIBISONO

Skripsi sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Statistika dan Sains Data

DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
INSTITUT PERTANIAN BOGOR
BOGOR
2024



Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber:
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

Tim Penguji pada Ujian Skripsi: 1 Ir. Aam Alamudi, M.Si.







Judul Skripsi : Penerapan Metode Hybrid GARCH-LSTM untuk Meramalkan

Harga Bawang Putih Nasional

: Akmal Riza Wibisono Nama

NIM : G1401201086

D .			1	1
Disetu	111	11	O	eh
215000	~. J ╰	~1	0,	

Pembimbing 1:
Dra. Itasia Dir

Dra. Itasia Dina Sulvianti, M.Si.

Pembimbing 2:

Akbar Rizki, S.Stat., M.Si.

Diketahui oleh

Ketua Departemen Statistika: Dr. Bagus Sartono, S.Si., M.Si. NIP 19780411 200501 1002

Tanggal Ujian:
4 Juli 2024

Tanggal Lulus:





- Hak Cipta Dilindungi Undang-undang

 1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
 2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

IPB University

PRAKATA

Puji dan syukur penulis panjatkan kepada Allah subhanaahu wa ta'ala atas segala karunia-Nya sehingga karya ilmiah ini berhasil diselesaikan. Tema yang dipilih dalam penelitian yang dilaksanakan sejak bulan Januari 2024 hingga bulan Juli 2024 ini ialah peramalan data deret waktu, dengan judul "Penerapan Metode Hybrid GARCH-LSTM untuk Meramalkan Harga Bawang Putih Nasional".

Penulis menyadari bahwa terselesaikannya karya ilmiah ini tidak terlepas dari adanya dukungan, bimbingan, dan nasehat dari berbagai pihak. Melalui prakata ini, penulis hendak menyampaikan apresiasi dan terima kasih kepada:

- 1. Bapak Budi Harsono, Ibu Siwi Aryantini, Octiani Rissa Widianti, dan Nidia Windy Carissa selaku orang tua dan adik yang tidak henti memberikan doa, dukungan, dan motivasi;
- 2. Ibu Dra. Itasia Dina Sulvianti, M.Si. dan Ibu Akbar Rizki, S.Stat., M.Si. selaku dosen pembimbing atas bimbingan dan arahan yang diberikan selama proses penyusunan karya ilmiah;
- 3. Bapak Aam Alamudi, M.Si. selaku dosen penguji sekaligus moderator seminar hasil dan Ibu Rahma Anisa, S.Stat. selaku moderator kolokium atas saran dan masukan yang diberikan dalam rangka perbaikan karya ilmiah;
- 4. Ibu Laily Nissa Atul Mualifah, S.Si., M.Si. atas kesediaannya memberikan penjelasan dan pemahaman terkait tema dan metode yang penulis gunakan dalam karya ilmiah;
- 5. seluruh pengurus Himpro GSB IPB Kabinet Inference yang telah memberi kepercayaan dan warna bagi kehidupan perkuliahan penulis;
- 6. Hanung, Aldi, Steven, Alfi, Nachnoer, Zahid, Dicky, Nabil, Alwi, Fadhlan, Nabila, Irma, Nana, April, Duwi, Ervina, dan teman-teman Statistika Angkatan 57 yang telah sama-sama berjuang dan saling menguatkan;
- 7. Bang Adit dan Bang Asyraf selaku kakak tingkat yang telah bersedia memberikan motivasi, saran, dan ilmu dalam penyusunan karya ilmiah;
- 8. sosok yang telah memberi dukungan dan motivasi kepada penulis untuk menjadi pribadi yang lebih baik; dan
- 9. seluruh rekan dan pihak lain yang tidak bisa penulis sebutkan satu per satu yang telah mendukung penyusunan karya ilmiah ini.

Akhir kata, penulis menyadari bahwa karya ilmiah ini masih jauh dari kata sempurna. Meskipun demikian, penulis berharap karya ilmiah ini dapat bermanfaat bagi pihak yang membutuhkan dan bagi kemajuan ilmu pengetahuan.

Bogor, Juli 2024

Akmal Riza Wibisono



IPB University

— Bogor Indonesia —

DAFTAR ISI

DA	FTAF	RTABEL	X
DA	FTAF	R GAMBAR	X
DA	FTAF	RLAMPIRAN	X
I	PENI 1.1 1.2	DAHULUAN Latar Belakang Tujuan	1 1 2
II	TINJ 2.1 2.2 2.3 2.4 2.5	AUAN PUSTAKA Harga Bawang Putih Generalized Autoregressive Conditional Heteroskedasticity (Long Short-Term Memory (LSTM) Time Series k-fold Cross Validation Hybrid GARCH-LSTM	3 3 (GARCH) 3 4 5 6
III	MET 3.1 3.2	ODE Data Prosedur Analisis Data	7 7 7
IV	4.1 4.2 4.3 4.4	IL DAN PEMBAHASAN Eksplorasi Data Kestasioneran Data Heterogenitas Ragam Pemodelan GARCH Pemodelan Hybrid GARCH-LSTM Peramalan	12 12 12 15 15 18 21
V	SIMI 5.1 5.2	PULAN DAN SARAN Simpulan Saran	23 23 23
DA	FTAF	R PUSTAKA	24
LA	MPIR	AN	27
RIV	VAY.	AT HIDUP	33



DAFTAR TABEL

1	Klasifikasi nilai MAPE	10
Ω ^H ¶k Cipt&nįlik√PB University	Skenario hyperparameter	10
Ha	Ringkasan uji ARCH-Lagrange Multiplier	15
42	Dugaan nilai parameter model GARCH	16
jote	Hasil diagnostik sisaan model GARCH(1,1)	17
6	Sisaan model GARCH(1,1) setelah langkah normalisasi	18
ili);	Hasil cross validation pada tiap fold berdasarkan nilai RMSE	20
87	Hasil peramalan model <i>hybrid</i> GARCH-LSTM	21
В		
[/] ni›	DAFTADCIAMDAD	
rers	DAFTAR GAMBAR	
ity		
1	Ilustrasi arsitektur LSTM (Mahjoub <i>et al.</i> 2022)	4
2	Ilustrasi time series k-fold cross validation dengan $k = 5$ (Packt 2019	
	dalam Assaad dan Hayek 2021)	5
3	Grafik pembagian data latih dan uji pada data harga bawang putih	
	nasional periode Juli 2021 s.d. Februari 2024	12
4	Plot Box-Cox data harga bawang putih nasional periode Juli 2021 s.d.	
	Februari 2024	13
5	Plot ACF data harga bawang putih nasional periode Juli 2021 s.d.	
	Februari 2024	13
6	Grafik deret waktu data w_t	14
7	Plot Box-Cox (a) dan plot ACF (b) data w_t	14
8	Perbandingan nilai aktual dan dugaan pada data w_t^* berdasarkan model	
	GARCH(1,1)	17
9	Perbandingan data aktual dan dugaan pada data harga asli bawang putih	
	nasional berdasarkan model GARCH(1,1)	18
10	Grafik sisaan model GARCH(1,1)	18
11	Skenario time series k-fold cross validation pada fold ke-5	19
12	Perbandingan data aktual dan dugaan pada sisaan model GARCH(1,1)	
	berdasarkan model LSTM	20
13	Perbandingan data aktual dan dugaan pada data harga bawang putih	
	nasional berdasarkan model hybrid GARCH-LSTM	21
14	Grafik hasil peramalan harga bawang putih nasional	22
	DAFTAR LAMPIRAN	
1		20
	Skenario time series k-fold cross validation dengan $k = 5$	28
2	Hasil peramalan model <i>hybrid</i> GARCH-LSTM 120 hari ke depan	29





- Hak Cipta Dilindungi Undang-undang

 1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
 a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
 b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
 2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

IPB University



I PENDAHULUAN

1.1 Latar Belakang

Data deret waktu, disebut juga sebagai data *time series*, merupakan sekumpulan amatan yang terkumpul secara kronologis. Dalam aplikasinya, analisis data deret waktu digunakan untuk menghasilkan ramalan yang menjadi landasan dalam pengambilan keputusan terhadap kejadian yang akan datang (Montgomery *et al.* 2015). Tidak hanya sekadar ramalan, analisis deret waktu digunakan pula untuk memahami perilaku data serta menjelaskan hubungan antaramatan dari waktu ke waktu (Juanda dan Junaidi 2011). Pada tahun 1951, Peter Whittle mengembangkan suatu pendekatan statistika melalui metode *Autoregressive Moving Average* (ARMA) untuk menganalisis data deret waktu. Metode ini mampu menjelaskan perilaku data deret waktu dengan baik dalam kondisi standar, yaitu kondisi data stasioner dan linear (Cryer dan Chan 2008).

Sering kali model dasar ARMA tidak dapat digunakan dalam memodelkan data di dunia nyata karena tidak terpenuhinya asumsi stasioneritas data. Prosedur differencing dalam model Autoregressive Integrated Moving Average (ARIMA) dapat digunakan sebagai solusi atas ketidakstasioneran data (Prasetyo et al. 2024). Asumsi lain yang perlu diperhatikan adalah kondisi homogenitas ragam. Tidak terpenuhinya asumsi ini lazim terjadi dalam data yang fluktuatif dan memiliki volatilitas yang tinggi, salah satunya adalah data harga bahan pangan. Berdasarkan penelitian Sumaryanto (2016), beberapa komoditas pangan di Indonesia terdeteksi memiliki heterogenitas ragam yang menyebabkan fluktuasi harga pada kurun waktu tertentu. Model ARIMA tidak mampu menjelaskan data dengan baik jika digunakan pada data tersebut akibat adanya kondisi heteroskedastisitas sehingga dikembangkan metode Autoregressive Conditional Heteroskedasticity (ARCH) dan Generalized Autoregressive Conditional Heteroskedasticity (GARCH) untuk mengatasi perubahan ragam pada jangka waktu tertentu (Jannah 2021).

Peramalan terhadap data deret tidak hanya dapat dilakukan melalui pendekatan statistika klasik, tetapi juga dapat pula dilakukan menggunakan metode deep learning, salah satunya adalah model Long Short-Term Memory (LSTM). Sebagai pengembangan dari metode Reccurent Neural Network (RNN), arsitektur LSTM terdiri atas memory cells dan beberapa gate yang mencegah hilang atau berlebihnya error dalam proses peramalan (Okut 2021). Penelitian yang dilakukan Hochreiter dan Schmidhuber (1997) pun menyatakan bahwa LSTM dapat secara efektif mempelajari pola dependensi data dalam jangka pendek dan panjang serta karakteristik nonlinear di dalamnya. Meskipun demikian, LSTM memiliki kekurangan dalam data yang terbatas. Mualifah (2022) menyatakan bahwa dalam kondisi tersebut, akurasi dari LSTM akan berkurang akibat adanya forget gate yang cenderung memprioritaskan current state dibanding nilai yang dihasilkan hidden state sebelumnya. Salah satu solusi untuk menangani hal tersebut adalah mengombinasikan model LSTM dengan model lainnya.

Metode *hybrid* antara model statistika klasik dan *deep learning* telah terbukti mampu menjelaskan pola linear dan nonlinear yang terdapat dalam data deret waktu dengan volatilitas tinggi. Lebih lanjut, metode *hybrid* juga mampu meningkatkan interpretabilitas data sekaligus meningkatkan akurasi prediksi dari data yang dianalisis (Wang *et al.* 2022). Hal ini dibuktikan oleh penelitian terdahulu yang

dilakukan oleh Kim dan Won (2018) yang menjelaskan bahwa model hybrid GARCH-LSTM menghasilkan nilai error prediksi indeks harga saham terendah dengan nilai mean absolute error (MAE) sebesar 1,07%. Penelitian lain mendapati bahwa model hybrid GARCH-LSTM menghasilkan prediksi harga saham yang lebih baik daripada model LSTM dan model GARCH dengan nilai mean absolute percentage error (MAPE) secara berurutan sebesar 6,03%, 9,07%, dan 13,89% (Mualifah 2022).

Sebagai salah satu komoditas pangan utama di Indonesia, harga bawang putih memiliki kecenderungan bergerak fluktuatif, nonstasioner, nonlinear, dan memiliki volatilitas tinggi (Guo et al. 2019). Mengacu pada publikasi Badan Pangan Nasional (2024), harga bawang putih nasional tercatat mengalami kenaikan sebesar 30,98% selama periode 2023–2024. Jika hal ini tidak diatasi, kenaikan harga bawang putih Berpotensi mengancam ketahanan dan kestabilan komoditas pangan mengingat bawang putih memiliki pangsa konsumsi sebesar 91,79% pada tahun 2022 serta menjadi bahan dasar sebagian besar olahan makanan di Indonesia (Sarah et al. 2023). Menimbang karakteristik-karakteristik tersebut, metode hybrid GARCH-LSTM diharapkan dapat menjadi metode yang tepat untuk digunakan dalam memodelkan dan meramalkan pergerakan harga bawang putih nasional.

1.2 Tujuan

Penelitian ini bertujuan memodelkan harga bawang putih nasional menggunakan metode hybrid GARCH-LSTM terbaik dan melakukan peramalan selama 120 hari, terhitung sejak Maret hingga Juni 2024, sehingga dapat bermanfaat bagi seluruh pemangku kepentingan dan pelaku ekonomi di masa mendatang.



II TINJAUAN PUSTAKA

2.1 Harga Bawang Putih

Sebagai salah satu komoditas pangan dengan pangsa pasar yang sangat tinggi di Indonesia, produksi bawang putih dalam negeri diharapkan mampu menjadi tumpuan untuk mengatasi kebutuhan konsumsi masyarakat. Namun, sejak terjadinya pandemi COVID-19, produksi bawang putih Indonesia terus menurun dari sebesar 88.000 ton menjadi 80.000 ton di tengah kebutuhan konsumsi mencapai 560.000 ton pada tahun 2020. Ketimpangan antara jumlah produksi dan konsumsi ini memicu pemerintah Indonesia untuk memberlakukan kebijakan impor dalam rangka menutup defisit kebutuhan (Kementan 2020). Seiring dengan hal tersebut, menurunnya minat petani untuk menanam bawang putih semakin meningkatkan ketergantungan Indonesia terhadap bawang putih impor (Hadianto *et al.* 2019). Hal ini dapat diamati pada lesunya pertumbuhan sektor pertanian yang hanya berkembang sebesar 1,46% di tengah perkembangan produk domestik bruto (PDB) sebesar 4,94% dibanding tahun sebelumnya (Helmi *et al.* 2024).

Hingga tahun 2022, tercatat bahwa 95% bawang putih yang beredar di masyarakat merupakan bawang putih impor (Sandra et al. 2022). Tingginya tingkat ketergantungan Indonesia atas komoditas bawang putih impor ini menyebabkan terjadinya ketidakpastian harga di masyarakat. Akibat tingginya impor, volatilitas harga yang terjadi tidak lagi dipengaruhi oleh rantai penawaran dan permintaan masyarakat semata, tetapi juga oleh harga komoditas impornya (Fitriadi et al. 2023). Ketidakstabilan harga yang terjadi ini diperparah oleh beberapa persoalan internal dan eksternal, di antaranya biaya logistik yang tinggi, peralihan fungsi lahan pertanian, konflik global, krisis iklim, hingga peningkatan utang negara dalam beberapa tahun terakhir secara eksponensial (Helmi et al. 2024).

2.2 Generalized Autoregressive Conditional Heteroskedasticity (GARCH)

Salah satu keadaan nonstandar yang sering terjadi dalam pemodelan data deret waktu adalah kondisi ragam yang tidak homogen. Nilai ragam yang tidak sama pada setiap amatan dalam data deret waktu memunculkan suatu fenomena yang disebut sebagai ragam kondisional (conditional variance). Eagle mengembangkan model ARCH pada tahun 1982 sebagai solusi untuk menangani tidak terpenuhinya asumsi tersebut. Bentuk umum model ARCH dapat diamati berdasarkan persamaan berikut (Cryer dan Chan 2008):

$$\begin{aligned} y_t &= \mu + \varepsilon_t \\ \varepsilon_t &= \sigma_{(t|t-1)} v_t \\ \sigma_{(t|t-1)}^2 &= \omega + \sum_{i=1}^p \alpha_i \varepsilon_{t-1}^2, \omega > 0, \alpha_i \ge 0 \end{aligned} \tag{1}$$

dengan y_t adalah data aktual pada waktu ke-t, μ adalah rataan model rataan, ε_t adalah sisaan pada waktu ke-t, v_t adalah peubah acak yang menyebar N(0,1) pada waktu ke-t, $\sigma^2_{(t|t-1)}$ adalah ragam kondisional pada waktu ke-t ketika ragam kondisional pada waktu ke-(t-1) diketahui, ω adalah rataan model ragam kondisional, α_i adalah koefisien ordo ke-i dengan $i \leq p$, dan p adalah ordo tertinggi dalam model ARCH.

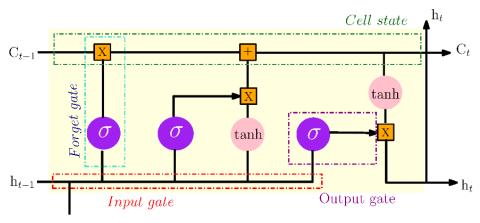
Bollerslev mengembangkan model GARCH pada tahun 1986 sebagai bentuk generalisasi dari model ARCH. Desvina dan Meijer (2018) menyatakan bahwa model GARCH dapat menghasilkan model yang lebih sederhana dengan menghindari ordo model ARCH yang terlalu besar. Bentuk umum model GARCH dapat diamati berdasarkan persamaan berikut (Cryer dan Chan 2008):

$$\sigma_{(t|t-1)}^2 = \omega + \sum_{i=1}^p \alpha_i \varepsilon_{t-1}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \text{ , } \omega > 0, \alpha_i \geq 0, \beta_j \geq 0 \qquad (2)$$

dengan β_j adalah koefisien ordo ke-j model GARCH dengan $j \leq q$, dan q adalah ordo tertinggi dalam model GARCH.

2.3 Long Short-Term Memory (LSTM)

Model LSTM merupakan salah satu metode peramalan deret waktu dengan pendekatan deep learning. Sebagai pengembangan dari model recurrent neural network (RNN), model LSTM menambahkan beberapa neuron tambahan berupa memory cell, input gate, forget gate, dan output gate dalam arsitekturnya untuk mencegah hilangnya atau menumpuknya nilai error dalam proses peramalan (Hochreiter dan Schmidhuber 1997). Ilustrasi arsitektur LSTM pada Gambar 1 menunjukkan neuron-neuron yang digunakan dan alur peramalan pada data input.



Gambar 1 Ilustrasi arsitektur LSTM (Mahjoub et al. 2022)

Mahjoub et al. (2022) menjelaskan bahwa proses peramalan data dalam model LSTM dimulai dengan masuknya data input (y_t) melalui *input gate* (i_t) . Proses optimasi berupa pendugaan parameter dan bias dalam model dilakukan melalui *hidden state* (h_t) yang terdiri atas *forget gate* (f_t) , *cell state* (c_t) , dan fungsi aktivasi. Dalam mekanisme optimasi di *hidden state*, fungsi aktivasi digunakan untuk menentukan bentuk dan skala data yang diproses (Assaad dan Hayek 2021). Terdapat dua fungsi aktivasi yang digunakan, yaitu fungsi aktivasi tanh yang mengubah nilai input ke dalam skala [-1,1] dan fungsi aktivasi sigmoid yang mengubah nilai input ke dalam skala [0,1] (Karlic dan Olgac 2011). Kedua fungsi aktivasi tersebut dapat diperoleh melalui persamaan berikut:

$$tanh(y) = \frac{e^{y} - e^{-y}}{e^{y} + e^{-y}}$$
(3)

$$\sigma(y) = \frac{1}{1 + e^{-y}} \tag{4}$$



Data yang telah melalui proses peramalan dalam *hidden state* selanjutnya akan dikeluarkan melalui *output gate* (o_t) . Fungsi *gate* dan *state* dalam model LSTM dapat dijelaskan melalui persamaan berikut (Okut 2021):

$$f_t = \sigma (W_f[h_{t-1}y_t] + b_f)$$
(5)

$$i_t = \sigma(W_i[h_{t-1}y_t] + b_i) \tag{6}$$

$$\widetilde{c_t} = \tanh(W_c[h_{t-1}y_t] + b_c) \tag{7}$$

$$c_t = f_t c_{t-1} + i_t \widetilde{c_t} \tag{8}$$

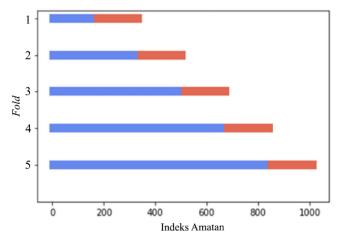
$$o_t = \sigma(W_0[h_{t-1}y_t] + b_0) \tag{9}$$

$$h_t = o_t \tanh(c_t) \tag{10}$$

dengan W_f , W_t , W_c , W_o merupakan nilai bobot untuk fungsi f_t , i_t , c_t , o_t , sedangkan b_f , b_i , b_c , b_o merupakan nilai bias untuk fungsi f_t , i_t , c_t , o_t , dan f_t merupakan fungsi f_t gate pada waktu ke- f_t . Selain itu f_t merupakan fungsi f_t me

2.4 Time Series k-fold Cross Validation

Metode *cross validation* digunakan untuk mengevaluasi kemampuan model dalam menduga nilai atau parameter secara konsisten dalam sampel yang berbeda. Metode ini digunakan untuk meningkatkan validitas model dalam melakukan generalisasi terhadap populasi dengan cara meminimalisasi bias dan menghindari *overfitting* (Nti *et al.* 2021). Dalam metode *cross validation* klasik, sampel yang digunakan dalam proses validasi diasumsikan saling bebas stokastik independen. Asumsi ini tidak terpenuhi pada data deret waktu yang memiliki autokorelasi antaramatan sehingga dikembangkan metode *time series k-fold cross validation* untuk memfasilitasi karakteristik tersebut (Assaad dan Fayek 2021).



Gambar 2 Ilustrasi time series k-fold cross validation dengan k = 5 (Packt 2019 dalam Assaad dan Hayek 2021)

Sebagai pengembangan terhadap data deret waktu, langkah validasi dalam metode time series k-fold cross validation akan selalu dilakukan pada data yang lebih baru. Hal tersebut berimplikasi pada pembagian data latih yang dilakukan pada deret waktu historis sehingga penentuan data uji pada setiap fold tidak dilakukan secara acak. Ilustrasi metode time series k-fold cross validation pada Gambar 2 menunjukkan langkah validasi yang dilakukan dengan membagi data menjadi sebanyak k fold dengan banyaknya data uji yang sama pada setiap foldnya. Kemampuan akurasi model pada data yang divalidasi dilakukan dengan menghitung rata-rata nilai akurasi model dari sebanyak k fold yang terbentuk.

2.5 **Hybrid GARCH-LSTM**

Metode hybrid GARCH-LSTM merupakan penggabungan metode statistika Rlasik berupa model GARCH dan deep learning berupa model LSTM untuk memodelkan suatu data deret waktu. Dalam metode hybrid GARCH-LSTM, model GARCH digunakan untuk menangkap pola linear dalam data. Sementara itu, penggunaan model LSTM ditujukan untuk menangkap pola nonlinear yang tidak bisa dijelaskan oleh model GARCH. Pemodelan hybrid GARCH-LSTM dimulai dengan melakukan pendugaan model terbaik dengan model GARCH. Sisaan dari model GARCH kemudian dijadikan data input dalam prosedur pemodelan LSTM (He et al. 2021). Oleh karena itu, data input untuk model LSTM dapat diperoleh melalui persamaan berikut:

$$e_t = y_t - \hat{y}_t \tag{11}$$

dengan e_t adalah sisaan pada waktu ke-t, y_t adalah nilai aktual pada waktu ke-t, dan \hat{y}_t adalah dugaan nilai pada waktu ke-t berdasarkan model GARCH.

Setelah prosedur pemodelan LSTM dilakukan, nilai dugaan final model hybrid GARCH-LSTM dapat diperoleh dengan menjumlahkan dugaan berdasarkan model GARCH dengan dugaan sisaan berdasarkan model LSTM. Perhitungan tersebut dapat diperoleh berdasarkan persamaan berikut:

$$\widehat{y_{h_t}} = \hat{y}_t + \hat{e}_t \tag{12}$$

dengan $\widehat{y_h}(t)$ adalah total dugaan nilai model hybrid GARCH-LSTM pada waktu ke-t, $\hat{y}(t)$ adalah dugaan nilai pada waktu ke-t berdasarkan model GARCH, dan $\hat{e}(t)$ adalah dugaan sisaan pada waktu ke-t berdasarkan model LSTM.



Ш **METODE**

3.1 Data

Penelitian ini menggunakan data sekunder berupa harga bawang putih bonggol nasional harian (yang selanjutnya akan disebut sebagai harga bawang putih nasional) dengan satuan berupa Rp/kg (Rupiah per kilogram). Sebanyak 974 amatan sejak tanggal 1 Juli 2021 hingga 29 Februari 2024 diambil sebagai objek penelitian. Data ini diperoleh dari Direktorat Stabilisasi Pasokan dan Harga Pangan Kedeputian Bidang Ketersediaan dan Stabilisasi Pangan Badan Pangan Nasional yang dapat diakses pada laman https://panelharga.badanpangan.go.id/.

Prosedur Analisis Data

Proses analisis data dilakukan menggunakan software R dan Python. Dokumentasi langkah-langkah analisis pada software yang digunakan dapat diamati pada laman https://github.com/akmalriza44/hybridGARCH-LSTM. Prosedur analisis dilakukan dengan tahapan sebagai berikut:

- 1. Melakukan eksplorasi data untuk mengamati tren dan karakteristik pergerakan harga.
- 2. Melakukan proses *splitting* data untuk menghasilkan data latih dan uji.
- 3. Melakukan uji stasioneritas ragam dan rataan
 - Mengidentifikasi stasioneritas ragam menggunakan plot Box-Cox. Data dikatakan stasioner dalam ragam jika memiliki nilai $\lambda = 1$ berada dalam selang kepercayaan 95% plot Box-Cox (Wahyuningsih et al. 2019). Jika data terdeteksi tidak stasioner dalam ragam, Box dan Cox (1964) mengajukan langkah transformasi untuk mengatasi ketidaknormalan dan heteroskedastisitas dalam data berdasarkan persamaan berikut:

$$z_t = y_t^{(\lambda)} = \begin{cases} y_t^{\lambda}, & \lambda \neq 0 \\ \ln(y_t), & \lambda = 0 \end{cases}$$
 (13)

dengan y_t merupakan amatan pada waktu ke-t.

b. Mengidentifikasi stasioneritas rataan menggunakan plot ACF dan uji Augmented Dickey-Fuller (ADF). Menurut Wahyuningsih et al. (2019), data yang tidak stasioner dalam rataan dapat diidentifikasi secara eksploratif jika plot ACF teramati turun secara perlahan (tails-off). Sementara itu, langkah identifikasi kestastioneran rataan melalui uji formal ADF dapat dilakukan dengan membentuk data deret waktu berdasarkan persamaan berikut (Cryer dan Chan 2008):

$$z_{t} = \rho_{1}z_{t-1} + \rho_{2}\Delta z_{t-1} + \rho_{3}\Delta z_{t-2} + \dots + \rho_{p}\Delta z_{t-p+1} + \varepsilon_{t}$$

$$z_{t-1} = \rho_{1}z_{t-2} + \rho_{2}\Delta z_{t-2} + \rho_{3}\Delta z_{t-3} + \dots + \rho_{p}\Delta z_{t-p} + \varepsilon_{t}$$

$$\operatorname{dengan} \Delta z_{t} = z_{t} - z_{t-1}, \operatorname{maka}$$

$$\Delta z_{t} = (\rho_{1} - 1)z_{t-1} + \sum_{i=2}^{p} \rho_{i}(\Delta z_{t-i+1}) + \varepsilon_{t}$$
(14)

dengan p merupakan ordo tertinggi model *autoregressive* (AR) dan \emptyset_p merupakan koefisien ordo ke-p model AR. Dickey dan Fuller (1979) menyatakan bahwa pengujian kestasioneran rataan data dapat dilakukan



melalui hipotesis, statistik uji, dan kriteria penolakan hipotesis nol berikut:

Hipotesis:

 $H_0: |\rho_1| = 1$ (data tidak stasioner)

 $H_1: |\rho_1| < 1$ (data stasioner)

Statistik uji:

$$t_{\widehat{\rho}_1} = \frac{\widehat{\rho_1}}{se(\widehat{\rho_1})} \tag{15}$$

dengan $\widehat{\rho_1}$ merupakan dugaan parameter ρ_1 dan $se(\widehat{\rho_1})$ merupakan galat baku dari $\widehat{\rho_1}$.

Skenario penolakan hipotesis:

Tolak H_0 jika $\left|t_{\widehat{\rho_1}}\right| > t_{a/2,n-p}$ atau p-value $< \alpha$ (0,05).

Apabila data terdeteksi tidak stasioner dalam rataan, perlu dilakukan proses *differencing* hingga data menjadi stasioner. Montgomery (2015) menjelaskan bahwa proses *differencing* berordo *d* dapat dijelaskan berdasarkan persamaan berikut:

$$w_t = z_t - z_{t-1} - \dots - z_{t-d} = (1 - B)^d z_t$$
 (16)

dengan z_t merupakan amatan yang sudah ditransformasi pada waktu ket dan B merupakan parameter backward shift.

4. Melakukan *rescaling* pada data hasil transformasi Box-Cox. Proses *rescaling* ditujukan untuk mendapatkan skala data yang cukup besar sehingga proses optimisasi dalam pendugaan parameter tidak terkonsentrasi dalam nilai mimimum lokal (Do dan Reynolds 2013). Proses *rescaling* dapat dilakukan berdasarkan persamaan berikut:

$$w_t^* = w_t \times 10^m \tag{17}$$

dengan m merupakan besar pangkat yang menghasilkan nilai w_t^* dengan skala yang diharapkan.

5. Mendeteksi efek heteroskedastisitas ragam dengan uji ARCH-LM. Pendeteksian heterogenitas ragam dilakukan pada data yang telah dikuadratkan dan diregresikan pada waktu ke-t hingga lag ke-p (Francq dan Zakoian 2019). Persamaan regresi tersebut dikenal sebagai model ARCH(p) yang dapat diperoleh berdasarkan Persamaan 1. Langkah uji formal ARCH-LM dapat dilakukan berdasarkan hipotesis, statistik uji, dan kriteria penolakan hipotesis nol sebagai berikut:

Hipotesis:

 $H_0: \alpha_1 = \alpha_2 = \cdots = \alpha_p = 0$, dengan p merupakan ordo tertinggi model ARCH (ragam homogen)

 H_1 : minimal ada satu $\alpha_i \neq 0$ untuk i = 1, 2, ..., p (ragam tidak homogen)

Statistik uji:

$$LM = nR^2 (18)$$

dengan n merupakan banyaknya amatan, R^2 merupakan koefisien determinasi dari persamaan ARCH(p), dan $LM \sim \chi^2_{p(\alpha)}$.

Skenario penolakan hipotesis:

Tolak H_0 jika $LM > \chi_{p(\alpha)}^2$ dengan $\alpha = 0.05$.

Jika berdasarkan uji ARCH-LM terdeteksi adanya heteroskedastisitas ragam, maka perlu dibangun model GARCH sebagai bentuk penanganan lanjutan (Juanda dan Junaidi 2011).

- 6. Membangun model GARCH
 - Mengidentifikasi kandidat ordo dan dugaan parameter model GARCH(p, q) dimulai dari ordo GARCH(1, 1).
 - b. Menghitung nilai AIC pada setiap model GARCH(p, q) yang terbentuk. Nilai AIC dapat diperoleh berdasarkan persamaan berikut (Montgomery et al. 2015):

$$AIC = \ln\left(\frac{\sum_{t=1}^{n} e_t^2}{n}\right) + \frac{2k}{n} \tag{19}$$

dengan e_t adalah sisaan dari model GARCH pada waktu ke-t, k adalah banyaknya parameter dalam model, dan n adalah banyaknya amatan.

c. Mengidentifikasi model GARCH(p,q) terbaik berdasarkan metrik AIC terkecil dan banyaknya parameter yang berpengaruh signifikan terbanyak. Montgomery et al. (2015) menyatakan bahwa pengujian signifikansi parameter dapat dilakukan melalui hipotesis, statistik uji, dan skenario penolakan hipotesis nol berikut:

Hipotesis:

 $H_0: \beta_i = 0$, untuk i = 1, 2, ..., q, dengan q merupakan ordo tertinggi GARCH (parameter tidak berpengaruh signifikan)

 $H_1: \beta_i \neq 0$, untuk i = 1, 2, ..., q (berpengaruh signifikan)

Statistik uji:

$$t_{\beta_i} = \frac{\widehat{\beta}_i}{se(\widehat{\beta}_i)} \tag{20}$$

dengan \hat{eta}_i merupakan dugaan parameter eta_i dan $se(\hat{eta}_i)$ merupakan galat baku dari $\hat{\beta}_i$.

Skenario penolakan hipotesis:

Tolak H_0 jika $\left|t_{\widehat{\beta}_i}\right| > t_{a/2,n-p}$ atau p-value $< \alpha$ (0,05).

- d. Membangkitkan nilai peubah acak $V \sim N(0,1)$ sejumlah banyaknya amatan (n).
- e. Menghitung dugaan nilai ragam kondisional dan dugaan harga bawang putih nasional berdasarkan model GARCH(p, q) terbaik.
- Melakukan diagnostik sisaan pada model GARCH (p,q) terbaik terhadap asumsi normalitas, autokorelasi, homogenitas, dan nilai tengah
- g. Melakukan evaluasi model GARCH dengan nilai MAPE pada data uji. Nilai MAPE dapat diperoleh berdasarkan persamaan berikut (Montgomery et al. 2015):

$$MAPE = \frac{1}{n} \sum_{t=1}^{n} \left| \frac{y_t - \widehat{y_t}}{y_t} \right| \times 100\%$$
 (21)

dengan y_t adalah nilai aktual harga bawang putih nasional pada waktu ke-t, $\widehat{y_t}$ adalah nilai ramalan pada waktu ke-t berdasarkan model



GARCH, dan n adalah banyaknya amatan. Nilai MAPE yang dihasilkan selanjutnya akan diklasifikasikan berdasarkan kriteria pada Tabel 1 untuk menentukan kategori akurasi model (Lewis 1982).

Tabel 1 Klasifikasi nilai MAPE

-					
	MAPE (%)	Kualitas Peramalan			
	<10	Sangat akurat			
	10-20	Baik			
	20-50	Wajar			
	>50	Tidak akurat			

- 7. Menghitung sisaan dari model GARCH terbaik berdasarkan persamaan 11. Sisaan model GARCH yang mengandung fitur nonlinear selanjutnya dijadikan sebagai input dalam pemodelan LSTM (He *et al.* 2021).
- 8. Membangun model hybrid GARCH-LSTM
 - a. Melakukan normalisasi data sisaan model GARCH menggunakan metode m*in-max normalization*. Proses normalisasi data dilakukan hingga menghasilkan data dengan skala [0,1] yang diperoleh berdasarkan persamaan berikut (Assaad dan Hayek 2021):

$$e_{t_{norm}} = \frac{e_t - \min(e)}{\max(e) - \min(e)}$$
 (22)

dengan $e_{t_{norm}}$ adalah nilai sisaan yang dinormalisasi pada waktu ke-t dan e_t adalah nilai sisaan model GARCH pada waktu ke-t.

b. Menentukan besar *time step* dan kombinasi skenario *hyperparameter* pada nilai *learning rate* dan *batch size* dalam pemodelan LSTM pada data latih. Skenario *hyperparameter* yang digunakan pada Tabel 2 merupakan modifikasi dari penelitian sebelumnya oleh Mualifah (2022), Riyadi (2024), dan Uskono (2023).

Tabel 2 Skenario hyperparameter

_	Hyperparameter				
Skenario	Time Step	Epoch	Optimizer	Learning Rate	Batch Size
Model 1				0,001	16
Model 2	20	100	100 Adam	0,001	32
Model 3	30	100		0,005	16
Model 4				0,005	32

Dikembangkan dari: Mualifah (2022), Riyadi (2024), Uskono (2023)

c. Melakukan pemilihan kombinasi *hyperparameter tuning* terbaik dengan menggunakan metode *time series k-fold cross validation* dengan k=5. Kombinasi *hyperparameter* terbaik ditentukan berdasarkan nilai ratarata *root mean squared error* (RMSE) terkecil pada data uji dari kelima *fold* yang terbentuk. Nilai RMSE dapat diperoleh berdasarkan persamaan berikut (Montgomery *et al.* 2015):

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^{n} (e_t - \widehat{e_t})^2}$$
 (23)

IPB University

Bogor Indonesia

dengan e_t adalah nilai sisaan model GARCH pada waktu ke-t, $\hat{e_t}$ adalah nilai dugaan sisaan pada waktu ke-t berdasarkan model LSTM, dan n adalah banyaknya amatan.

d. Melakukan denormalisasi data ke skala semula menggunakan metode *inverse transform* berdasarkan persamaan berikut:

$$e_t = e_{t_{norm}}[\max(e) - \min(e)] + \min(e)$$
(24)

dengan e_t adalah nilai sisaan yang telah didenormalisasi pada waktu ket dan $e_{t_{norm}}$ adalah nilai sisaan model GARCH setelah dinormalisasi pada waktu ke-t.

- 9. Menentukan nilai akhir dugaan model *hybrid* GARCH-LSTM dengan menjumlahkan dugaan harga bawang putih berdasarkan model GARCH dan dugaan sisaan berdasarkan model LSTM. Perhitungan nilai dugaan model *hybrid* GARCH-LSTM dapat diperoleh berdasarkan Persamaan 12.
- 10. Melakukan evaluasi model *hybrid* GARCH-LSTM dengan nilai MAPE pada data uji. Nilai MAPE untuk model *hybrid* GARCH-LSTM dapat diperoleh berdasarkan persamaan berikut (Montgomery *et al.* 2015):

$$MAPE = \frac{1}{n} \sum_{t=1}^{n} \left| \frac{y_t - \widehat{y_h}_t}{y_t} \right| \times 100\%$$
 (25)

dengan y_t adalah nilai aktual harga bawang putih nasional pada waktu ke-t, $\widehat{y_{h_t}}$ adalah nilai ramalan pada waktu ke-t berdasarkan model hybrid GARCH-LSTM, dan n adalah banyaknya amatan. Kualitas akurasi model hybrid GARCH-LSTM kemudian akan diklasifikasikan berdasarkan kriteria nilai MAPE yang ditampilkan pada Tabel 1.

11. Melakukan peramalan harga bawang putih dalam 120 hari ke depan (sejak tanggal 1 Maret 2024 hingga 28 Juni 2024) berdasarkan model *hybrid* GARCH-LSTM.

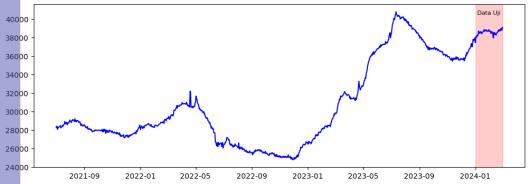


HASIL DAN PEMBAHASAN IV

Eksplorasi Data

Langkah eksplorasi data ditujukan untuk mengamati tren dan karakteristik pergerakan harga bawang putih nasional harian. Grafik pergerakan harga bawang putih nasional pada Gambar 3 memperlihatkan fluktuasi harga yang terus terjadi dalam kurun waktu tahun 2021 hingga 2024. Fluktuasi harga ini disebabkan oleh ingginya pasokan bawang putih impor di Indonesia akibat defisit produksi sehingga menyebabkan harga yang tidak lagi hanya dipengaruhi oleh faktor permintaan dan penawaran pasar lokal, tetapi juga faktor global sebagai pemasok produk impor (Fitriadi *et al.* 2023). Ketidakstabilan harga ini diperparah dengan adanya krisis iklim melalui fenomena El Nino sejak tahun 2023 yang menyebabkan semakin terganggungnya ketersediaan pasokan bawang putih (Mawarni et al. 2024). Kedua hal tersebut, menurut Kementerian Perdagangan, menjadi faktor utama yang menyebabkan kenaikan drastis hampir seluruh harga pangan di Indonesia sejak kuartal pertama tahun 2023 hingga kuartal kedua tahun 2024.

Fluktuasi harga bawang putih dapat diamati pada Gambar 1 dan terus terjadi dalam kurun waktu tahun 2021 hingga 2024. Sebanyak 904 amatan sejak Juli 2021 hingga Desember 2023 ditentukan sebagai data latih karena teramati memiliki dua tren kenaikan (Juli 2021–April 2022 dan Januari–Juli 2023) dan dua tren penurunan (Mei–Desember 2022 dan Agustus–Desember 2023). Sementara itu, kesamaan faktor eksternal serta kemiripan pola data antara penghujung tahun 2023 dan awal tahun 2024 menjadi pertimbangan dalam menentukan sebanyak 60 amatan pada bulan Januari–Februari 2024 menjadi data uji.



Grafik pembagian data latih dan uji pada data harga bawang putih nasional periode Juli 2021 s.d. Februari 2024

4.2 **Kestasioneran Data**

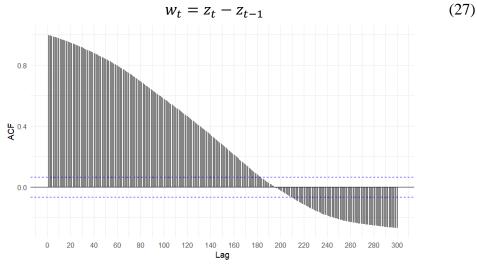
Pendeteksian kestasioneran ragam dan rataan pada data harga bawang putih nasional dilakukan secara eksploratif melalui plot Box-Cox dan ACF dan diperkuat melalui uji formal ADF. Langkah identifikasi kestasioneran menunjukkan bahwa data tidak stasioner dalam ragam maupun rataan. Ketidakstasioneran dalam ragam dapat diamati pada Gambar 4 yang menunjukkan nilai λ sebesar -0,95, sehingga milai $\lambda = 1$ tidak berada dalam selang kepercayaan 95%. Mengacu pada bentuk fungsi transformasi Box dan Cox (1964), perlu dilakukan transformasi pada data harga bawang putih nasional (y_t) dengan persamaan sebagai berikut:

DR I DIVERSITY

 $z_{t} = y_{t}^{-1}$ $z_{t} = y_{t}^{-1}$

Gambar 4 Plot Box-Cox data harga bawang putih nasional periode Juli 2021 s.d. Februari 2024

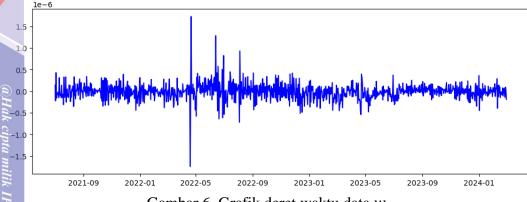
Sementara itu, ketidakstasioneran dalam rataan dapat diamati pada Gambar 5 yang menunjukkan pola *tails-off* pada plot ACF. Hal ini diperkuat dengan uji formal ADF yang menghasilkan p-value sebesar 0,842 sehingga disimpulkan bahwa hipotesis nol tidak ditolak dan data mengalami ketidakstasioneran rataan dalam taraf nyata 5%. Montgomery et al. (2015) menyatakan bahwa kondisi ketakstasioneran rataan dapat ditangani dengan melakukan langkah *differencing* satu kali dengan bentuk persamaan sebagai berikut:



Gambar 5 Plot ACF data harga bawang putih nasional periode Juli 2021 s.d. Februari 2024

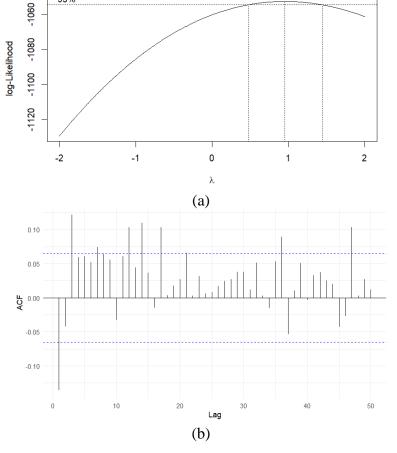
Gambar 6 menunjukkan grafik harga bawang putih nasional setelah melalui langkah transformasi dan *differencing* satu kali (w_t) . Secara eksploratif, dapat diamati bahwa data w_t sudah berada dalam rataan yang konstan pada nilai nol dan ragam yang lebih homogen. Langkah uji formal melalui uji ADF serta plot ACF dan Box-Cox perlu dilakukan untuk memperkuat dugaan tersebut.





Gambar 6 Grafik deret waktu data w_t

Pemeriksaan kestasioneran pada data w_t menunjukkan bahwa data setelah proses transformasi dan differencing satu kali telah memenuhi asumsi stasioneritas dalam ragam maupun rataan. Ketidakstasioneran dalam ragam dapat diamati pada Gambar 7(a) yang menunjukkan nilai λ sebesar 0,95 dengan nilai $\lambda = 1$ yang berada dalam selang kepercayaan 95%. Sementara itu, plot ACF pada Gambar 7(b) yang memperlihatkan pola *cut-off* menunjukkan bahwa data w_t telah stasioner dalam rataan. Dugaan eksploratif ini diperkuat dengan hasil uji formal ADF yang menghasilkan p-value yang lebih kecil dari 0,01 sehingga memenuhi syarat untuk menolak hipotesis nol yang menyatakan bahwa data telah mengalami kestasioneran rataan dalam taraf nyata 5%.



Gambar 7 Plot Box-Cox (a) dan plot ACF (b) data w_t



4.3 Heterogenitas Ragam

Pendeteksian heterogenitas ragam dilakukan dengan mengidentifikasi efek ARCH menggunakan uji ARCH-LM. Langkah pengujian heterogenitas ragam dilakukan terhadap data w_t yang memiliki skala data dalam rentang $[10^{-6}, 10^{-7}]$. Skala data w_t yang sangat kecil imbas dari proses transformasi dan differencing tersebut berpotensi menimbulkan kesalahan pendugaan parameter dan nilai statistik uji. Kesalahan ini dipicu oleh pencarian nilai optimum yang berpotensi telah konvergen pada titik lokal optimum (Do dan Reynolds 2013). Salah satu langkah penanganan untuk mendapatkan skala data yang sesuai adalah melalui proses rescaling pada data w_t hingga mencapai skala yang cukup besar, yaitu dalam rentang $[10^0, 10^2]$, sebagai berikut:

$$w_t^* = w_t \times 10^8 \tag{28}$$

Penolakan terhadap hipotesis nol yang ditunjukkan dengan p-value yang bernilai lebih kecil dari taraf nyata bermakna adanya indikasi heterogenitas ragam pada data yang diuji. Ringkasan terhadap hasil uji ARCH-LM pada data w_t^* dapat diamati pada Tabel 3. Hasil uji ARCH-LM yang disajikan pada Tabel 3 menunjukkan p-value yang lebih kecil daripada taraf nyata 5% pada lag ke-2 hingga lag ke-24. Hal ini memenuhi syarat penolakan terhadap hipotesis nol sehingga dapat disimpulkan bahwa terdapat efek ARCH/GARCH yang mengindikasikan adanya keheterogenan ragam pada data hingga lag ke-24 dalam taraf nyata 5%. Pada penelitian yang dilakukan Desvina dan Meijer (2018), disebutkan bahwa data yang terindikasi memiliki keheterogenan ragam hingga lebih dari lag ke-12 lebih cocok dimodelkan menggunakan model GARCH dibanding model ARCH. Model GARCH dipilih karena mampu menghindari penggunaan lag yang terlalu tinggi pada model ARCH sehingga menghasilkan model yang lebih sederhana (Angraini et al. 2024).

Tabel 3 Ringkasan uji ARCH-Lagrange Multiplier

	<u> </u>	
Lag	Statistik LM	p-value
2	219,865	<0,001*
4	285,282	<0,001*
6	311,333	<0,001*
:	:	:
20	333,790	<0,001*
22	333,340	<0,001*
24	332,924	<0,001*

^{*}Signifikan dalam taraf nyata 5%

4.4 Pemodelan GARCH

Penentuan dugaan parameter GARCH untuk memodelkan ragam data w_t^* dimulai dari ordo GARCH(1,1) hingga GARCH(2,2). Mekanisme penentuan ordo ini dilakukan guna mengidentifikasi adanya dugaan parameter yang signifikan pada ordo yang lebih tinggi. Model GARCH terbaik selanjutnya ditentukan berdasarkan nilai AIC terkecil dan signifikansi dugaan parameter model. Ringkasan pendugaan parameter yang disajikan pada Tabel 4 menunjukkan bahwa model terbaik yang terbentuk adalah model ragam GARCH(1,1) dengan nilai AIC terkecil dan

banyaknya parameter yang signifikan dalam taraf nyata 5% terbanyak dibandingkan dengan model lainnya.

Tabel 4 Dugaan nilai parameter model GARCH

<u>@</u>	Model GARCH	Parameter	Koefisien Parameter	p-value	AIC
Ha		μ	-1,592	0,046*	
k ci	CADCII(1.1)	ω	34,652	0,165	7 900 90
pta	GARCH(1,1)	$lpha_1$	0,138	0,002*	7.899,89
mi		eta_1	0,780	<0,001*	
lik .		μ	-1,631	0,076	
PB		ω	37,915	0,220	
U	GARCH(2,1)	$lpha_1$	0,119	0,070	7.901,28
iva		α_2	0,036	0,691	
ersi.		eta_1	0,757	<0,001*	
Ť		μ	-1,592	0,058	
		ω	34,655	0,129	
	GARCH(1,2)	$lpha_1$	0,138	0,005*	7.901,89
		eta_1	0,780	0,005*	
_		eta_2	0,000	1,000	
		μ	-1,649	0,080	
		ω	51,755	0,226	
	GARCH(2,2)	$lpha_1$	0,115	0,068	7.902,64
	UARCH(2,2)	$lpha_2$	0,102	0,272	1.702,04
		eta_1	0,369	0,182	
		eta_2	0,296	0,120	

^{*}Parameter yang signifikan dalam taraf nyata 5%

Model GARCH(1,1) sebagai model terbaik yang ditampilkan pada Tabel 4 menghasilkan tiga dugaan parameter yang signifikan, yaitu parameter μ , α_1 , dan β_1 . Signifikansi parameter μ menunjukkan bahwa rataan model dengan suatu nilai konstanta memberikan pengaruh yang signifikan dalam taraf nyata 5% ketika digunakan untuk memodelkan data w_t^* . Sementara itu, tidak signifikannya parameter ω menunjukkan bahwa dalam taraf nyata 5%, tidak ada nilai yang tidak bisa dijelaskan untuk memodelkan ragam kondisional pada waktu ke-t (σ_t) selain berdasarkan nilai sisaan (ε_{t-1}) dan ragam kondisional (σ_{t-1}) pada satu periode sebelumnya. Berdasarkan hal tersebut, model GARCH(1,1) dapat dituliskan dalam persamaan sebagai berikut:

$$w_t^* = -1,592 + \varepsilon_t$$

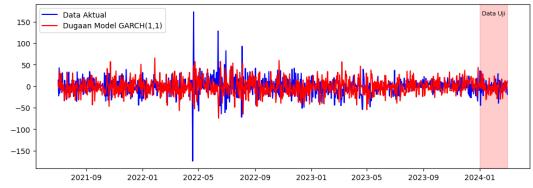
$$\varepsilon_t = \sigma_{(t|t-1)} v_t$$

$$\sigma_{(t|t-1)}^2 = 0,138\varepsilon_{t-1}^2 + 0,780\sigma_{t-1}^2$$
(29)

Model GARCH(1,1) selanjutnya digunakan untuk menduga nilai data w_t^* pada data latih. Perbandingan antara nilai aktual dan dugaan data w_t^* pada Gambar menunjukkan performa model GARCH(1,1) yang mampu menduga pola volatilitas dengan cukup baik. Meskipun demikian, dapat teramati pula dugaan nilai yang overestimate maupun underestimate pada beberapa periode data ketika



volatilitas yang terjadi sangat tinggi. Hal serupa teramati pula pada pola dugaan data yang dihasilkan dalam data uji sehingga model tidak menunjukkan indikasi *overfitting*.



Gambar 8 Perbandingan nilai aktual dan dugaan pada data w_t^* berdasarkan model GARCH(1,1)

Diagnostik sisaan pada model terbaik dilakukan terhadap asumsi kebebasan, kehomogenan ragam, normalitas, dan nilai harapan sisaan. Ringkasan hasil diagnostik sisaan model GARCH(1,1) pada Tabel 5 menunjukkan bahwa hanya asumsi normalitas sisaan yang tidak terpenuhi dalam taraf nyata 5%. Meskipun demikian, sisaan yang tidak menyebar normal dapat ditoleransi pada data dengan jumlah besar sebagaimana yang dijelaskan dalam teorema limit pusat (Maharani *et al.* 2023). Teorema tersebut menjelaskan bahwa suatu data yang memiliki banyaknya amatan lebih dari atau sama dengan 30 dapat didekati dengan sebaran normal (Anderson *et al.* 2011 dalam Lestari *et al.* 2022). Pendekatan melalui teorema limit pusat menunjukkan terpenuhinya seluruh asumsi terhadap sisaan model GARCH(1,1). Hal ini mengindikasikan model yang telah tepat dan menghasilkan dugaan nilai yang valid.

Tabel 5 Hasil diagnostik sisaan model GARCH(1,1)

Asumsi Sisaan	Uji Formal	p-value	Kesimpulan
Autokorelasi	Uji Ljung-Box	0,145	Sisaan saling bebas
Homogenitas	Uji ARCH-LM	0,994	Ragam sisaan homogen
Normalitas	Uji Kolmogorov- Smirnov	0,002	Sisaan tidak menyebar normal
Nilai harapan sisaan nol	Uji-t	0,320	Nilai harapan sisaan nol

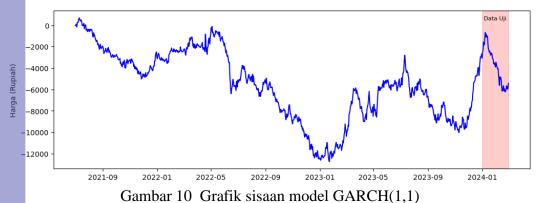
Transformasi model GARCH(1,1) dari bentuk data w_t^* dilakukan untuk mendapatkan dugaan nilai harga asli bawang putih nasional $(\hat{y_t})$. Gambar 9 menunjukkan nilai dugaan harga bawang putih yang secara umum *overestimate* hampir pada seluruh periode data. Meskipun demikian, dugaan harga bawang putih dapat teramati memiliki pola volatilitas dan tren kenaikan maupun penurunan harga yang cenderung sama dengan pola yang terjadi pada data latih aktual. Evaluasi terhadap model GARCH(1,1) pada data uji menghasilkan nilai MAPE sebesar 9,73% sehingga dapat dikategorikan sebagai model yang memiliki kemampuan peramalan sangat akurat. Hal ini menunjukkan salah satu keunggulan dari model GARCH, yaitu mampu menangkap pola volatilitas yang teramati pada data dengan baik (Aklimawati dan Wahyudi 2013).

25000 - Data Aktual Dugaan Model GARCH(1,1) Dugaan Mod

Gambar 9 Perbandingan data aktual dan dugaan pada data harga asli bawang putih nasional berdasarkan model GARCH(1,1)

4.5 Pemodelan Hybrid GARCH-LSTM

Langkah pemodelan hybrid GARCH-LSTM dilakukan dengan menjadikan sisaan dari model GARCH(1,1) (e_t) sebagai input dalam pemodelan LSTM. Gambar 10 menunjukkan sisaan model GARCH(1,1) pada harga bawang putih nasional yang bernilai negatif hampir sepanjang periode amatan. Pola nonlinear yang dihasilkan selanjutnya akan dimodelkan menggunakan metode LSTM.



Sebagai langkah optimalisasi, data input dalam pemodelan LSTM perlu dinormalisasi sehingga memiliki skala yang sama dan relatif kecil untuk meminimalisasi terjadinya bias dan mempercepat proses komputasi (Nayak *et al.* 2014). Dalam penelitian serupa yang dilakukan oleh Firdaus *et al.* (2023), proses normalisasi terhadap data input dalam pemodelan LSTM dilakukan menggunakan metode *min-max normalization* untuk menghasilkan data dengan skala [0,1]. Hasil normalisasi pada sisaan model GARCH(1,1) dapat diamati pada Tabel 6.

Tabel 6 Sisaan model GARCH(1,1) setelah langkah normalisasi

Tanggal	Sisaan	Normalisasi
01/07/2021	0	0,949
02/07/2021	-49,509	0,945
03/07/2021	97,608	0,956
:	:	:
27/02/2024	-5.965,083	0,505
28/02/2024	-5.962,208	0,505
29/02/2024	-5.433,318	0,544

Pembangunan model LSTM dilakukan dengan menentukan hyperparameter yang berpengaruh signifikan terhadap proses pembelajaran data dan akurasi peramalan, di antaranya time step, epoch, learning rate, dan batch size (Raiaan et al. 2024). Masri et al. (2020) menyatakan bahwa penentuan besar time step penting dilakukan dalam pemodelan LSTM guna memperhitungkan banyaknya data dari periode sebelumnya yang akan dipelajari oleh model dalam proses peramalan. Penentuan time step sebesar 30 dalam penelitian ini diharapkan mampu menangkap informasi harga bawang putih selama sebulan terakhir. Hal ini didasari atas penelitian yang dilakukan oleh Darma et al. (2018) yang menunjukkan bahwa fluktuasi bulanan harga pangan di Indonesia memiliki dampak yang signifikan terhadap perekonomian nasional.

Penentuan kombinasi hyperparameter lainnya, yaitu epoch, learning rate, dan batch size dapat diamati pada Tabel 1. Kombinasi hyperparameter yang dipertimbangkan merupakan besar hyperparameter yang memberikan hasil peramalan terbaik dalam penelitian Mualifah (2022), Riyadi (2024), dan Uskono (2023). Sementara itu, optimizer Adam dipilih karena mampu menjalankan komputasi optimasi parameter dengan lebih efisien sehingga menghasilkan peramalan yang lebih akurat (Ba dan Kigma 2015 dalam Riyadi 2024).

Tahap hyperparameter tuning melibatkan pengujian terhadap seluruh kombinasi hyperparameter yang telah ditentukan untuk mengidentifikasi model yang paling optimum dan menghasilkan ramalan yang paling akurat. Validasi terhadap langkah hyperparameter tuning dilangsungkan dengan menggunakan metode time series k-fold cross validation dengan besar k = 5. Penentuan besar fold pada metode validasi tersebut didasari atas penelitian Le et al. (2024) yang menyatakan bahwa banyaknya fold antara 5 hingga 10 sudah optimum untuk digunakan dalam memodelkan data deret waktu yang memiliki anomali dan fluktuasi yang tinggi. Skenario partisi data input pada setiap fold yang terbentuk dapat diamati pada Lampiran 1 dengan ketentuan setiap fold memiliki banyaknya data uji yang serupa. Skenario pembagian data latih dan uji pada seluruh data pada fold ke-5 dapat diamati pada Gambar 11 sebagai berikut.



Gambar 11 Skenario time series k-fold cross validation pada fold ke-5

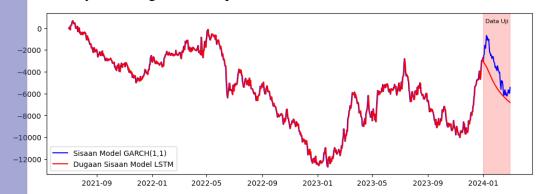
Proses validasi untuk menentukan kombinasi hyperparameter terbaik dilakukan dengan memperhatikan hasil dugaan data input LSTM pada data uji di setiap fold yang terbentuk. Hyperparameter terbaik ditentukan berdasarkan ratarata nilai RMSE terkecil pada data yang sudah didenormalisasi menggunakan metode inverse transform pada kelima fold dalam setiap langkah cross validation. Ringkasan hasil time series k-fold cross validation pada Tabel 7 menunjukkan

bahwa nilai RMSE memiliki kecenderungan mengecil seiring dengan peralihan menuju *fold* akhir. Hal ini mengindikasikan peningkatan akurasi peramalan model LSTM dengan penambahan banyaknya data latih. Melalui tabel yang sama, skenario *hyperparameter* terbaik terindikasi dihasilkan oleh Model 3 dengan nilai RMSE sebesar 137,18. Model ini menggunakan nilai *learning rate* sebesar 0,005 dan *batch size* sebesar 16. Penentuan skenario model terbaik ini didasari atas ratarata nilai RMSE kelima *fold* yang secara signifikan lebih kecil dibandingkan dengan skenario model lainnya yang dievaluasi melalui tahapan *time series k-fold cross validation*.

Tabel 7 Hasil cross validation pada tiap fold berdasarkan nilai RMSE

Fold	Model 1	Model 2	Model 3	Model 4
1	375,63	478,58	26,37	200,80
2	585,06	1.290,21	114,28	130,28
3	824,15	1.449,39	543,28	630,70
4	22,42	97,56	0,46	5,35
5	17,81	70,32	1,5	12,92
Rata-rata	365,01	677,21	137,18	196,01

Serangkaian langkah cross validation menggunakan empat skenario kombinasi hyperparameter menunjukkan bahwa model LSTM terbaik untuk memodelkan sisaan GARCH(1,1) adalah model dengan time step sebesar 30, epoch sebesar 100, learning rate sebesar 0,005, batch size sebesar 16, dan menggunakan optimizer Adam. Pendugaan nilai sisaan ($\widehat{e_t}$) menggunakan model tersebut menunjukkan hasil yang relatif underestimate pada data uji. Meskipun demikian, grafik perbandingan antara data aktual dan ramalan pada Gambar 12 menunjukkan bahwa dugaan nilai sisaan pada data uji menghasilkan pola data yang serupa dengan data aktual, yaitu mengalami tren penurunan.

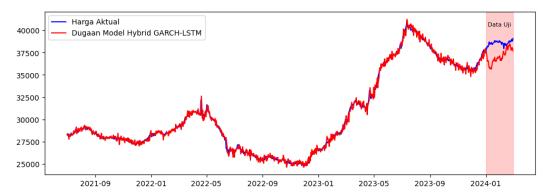


Gambar 12 Perbandingan data aktual dan dugaan pada sisaan model GARCH(1,1) berdasarkan model LSTM

Setelah pemodelan sisaan menggunakan metode LSTM selesai dilakukan, pendugaan harga bawang putih nasional $(\widehat{y_h}_t)$ dapat dilakukan dengan menjumlahkan dugaan harga bawang putih berdasarkan model GARCH $(\widehat{y_t})$ dan dugaan sisaan berdasarkan model LSTM terbaik $(\widehat{e_t})$. Grafik yang dapat diamati pada Gambar 13 menunjukkan adanya tren kenaikan harga yang sama-sama terjadi, baik pada data aktual maupun data hasil peramalan menggunakan model *hybrid* GARCH-LSTM. Evaluasi terhadap model *hybrid* GARCH-LSTM terbaik pada data uji menghasilkan nilai MAPE sebesar 3,84% sehingga dapat dikategorikan

DR Holyereity

sebagai model dengan kemampuan peramalan yang sangat akurat (Lewis 1982). Nilai MAPE tersebut juga menunjukkan bahwa prosedur pemodelan sisaan menggunakan model LSTM pada model *hybrid* GARCH-LSTM berhasil meningkatkan akurasi pendugaan harga bawang putih nasional yang dapat diamati berdasarkan penurunan nilai MAPE pada data uji.



Gambar 13 Perbandingan data aktual dan dugaan pada data harga bawang putih nasional berdasarkan model *hybrid* GARCH-LSTM

4.6 Peramalan

Model *hybrid* GARCH-LSTM selanjutnya digunakan untuk menghasilkan ramalan harga bawang putih nasional selama 120 hari, yaitu periode Maret–Juni 2024. Perhitungan hasil peramalan menggunakan metode *hybrid* GARCH-LSTM dapat dilakukan berdasarkan Persamaan 12. Ringkasan hasil peramalan pada Tabel 8 menunjukkan adanya kenaikan harga bawang putih nasional sebesar Rp7.500/kg dalam kurun waktu empat bulan. Melalui tabel yang sama, dapat diamati hasil ramalan harga bawang putih nasional berdasarkan model GARCH(1,1) yang terus meningkat seiring dengan pertambahan periode peramalan. Sebaliknya, sisaan model GARCH(1,1) berdasarkan model LSTM diramalkan terus mengalami penurunan yang menyebabkan hasil ramalan final model *hybrid* GARCH-LSTM terus berfluktuasi hingga akhir periode peramalan. Rincian hasil permalaan harga bawang putih nasional berdasarkan model GARCH(1,1), LSTM, dan *hybrid* GARCH-LSTM dapat diamati sepenuhnya pada Lampiran 2.

Tabel 8 Hasil peramalan model hybrid GARCH-LSTM

Tanggal	GARCH(1,1)	LSTM	Hybrid
01/03/2024	44.387,98	-6.856,57	37.531,41
02/03/2024	44.466,65	-6.889,59	37.577,07
03/03/2024	44.273,48	-6.922,03	37.351,46
:	:	:	:
26/06/2024	54.915,30	-8.716,00	46.199,30
27/06/2024	54.260,96	-8.723,23	45.537,74
28/06/2024	53.854,66	-8.730,35	45.124,31

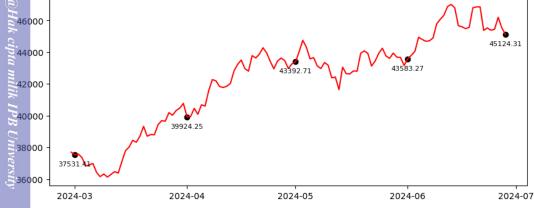
Hasil peramalan yang disajikan pada Gambar 14 menunjukkan tren peningkatan harga hingga menyentuh kisaran Rp45.000/kg pada akhir bulan Juni 2024. Selain harga bawang putih nasional yang diramalkan terus meningkat, pola volatilitas harga pun diramalkan akan terus terjadi hingga akhir periode peramalan. Ketidakstabilan dan kecenderungan melonjaknya harga bawang putih nasional ini



Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan k Pengutipan tidak merugikan kepentingan yang wajar IPB University.

IPB University

sesuai dengan pernyataan Helmi et al. (2024) yang menyatakan bahwa harga pangan pada tahun 2024 akan mengalami disrupsi besar akibat kondisi lokal dan global, di antaranya konflik Rusia-Ukraina dan Israel-Palestina, krisis iklim, hingga efek peningkatan utang Indonesia secara eksponensial dalam beberapa tahun terakhir.



Gambar 14 Grafik hasil peramalan harga bawang putih nasional



V SIMPULAN DAN SARAN

5.1 Simpulan

Penggunaan model *hybrid* GARCH-LSTM dapat digunakan untuk meningkatkan akurasi peramalan pada data deret waktu yang nonstasioner, nonlinear, dan memiliki volatilitas tinggi dengan tetap mempertahankan kemampuan statistika klasik dalam menginterpretasikan model. Harga bawang putih nasional, sebagai salah satu harga bahan pangan di Indonesia yang memiliki volatilitas tinggi, mampu dimodelkan menggunakan model *hybrid* GARCH-LSTM. Model ini dapat menurunkan nilai MAPE dari 9,73% (model GARCH(1,1)) menjadi 3,84%. Prosedur pemodelan sisaan dengan LSTM berhasil meningkatkan akurasi dan dapat dikategorikan sebagai model yang sangat akurat dalam meramalkan harga bawang putih nasional. Hasil peramalan terhadap harga bawang putih nasional menunjukkan tren kenaikan yang disertai fluktuasi harga hingga menyentuh kisaran Rp45.000/kg pada akhir Juni 2024.

5.2 Saran

Penelitian selanjutnya mengenai peramalan harga bawang putih yang menunjukkan volatilitas tinggi diharapkan mempertimbangkan penggunaan variasi model GARCH dan metode deep learning lain, antara lain Exponential GARCH (EGARCH), Predictive GARCH (PGARCH), Gated Recurrent Unit (GRU), hingga Convolutional Neural Network (CNN). Keterbatasan dalam penentuan skenario hyperparameter pada penelitian ini dapat dikembangkan dengan mengombinasikan hyperparameter lain untuk mendapatkan model yang lebih optimum. Selain itu, untuk meningkatkan akurasi peramalan, dapat dipertimbangkan pula penambahan peubah lain dalam analisis deret waktu multivariat sebagai faktor eksternal yang memiliki pengaruh signifikan terhadap harga bawang putih.



DAFTAR PUSTAKA

- Aklimawati L, Wahyudi T. 2013. Estimasi volatilitas return harga kakao menggunakan model ARCH dan GARCH. *Pelita Perkebunan*. 29(2): 142–158.
- graini Y, Pangestika AP, Sumertajaya IM. 2024. Comparison of the symmetric and asymmetric generalized autoregressive conditional heteroscedasticity (GARCH) models in forecasting the 2018–2023 Jakarta composite index. *ComTech: Computer, Mathematics, and Engineering Applications*. 15(1):1–5. doi:10.21512/Comtech.v15i1.10610.
- Asaad RH, Fayek S. 2021. Predicting the price of crude oil and its fluctuations using computational econometrics: deep learning, LSTM, and convolutional neural networks. *Econometrics Research in Finance*. 6(2):119–137. doi:10.2478/erfin-2021-0006.
- Bapanas] Badan Pangan Nasional. 2024. Harga Rata Rata Nasional [diakses 11 Maret 2024]. https://panelharga.badanpangan.go.id/.
- Box GEP, Cox DR. 1964. An analysis of transformations revisited. *Journal of the American Statistical Association*. 76:296–311.
- Cryer JD, Chan K. 2008. *Time Series Analysis with Applications in R*. Ed ke-2. New York: Springer.
- Darma DC, Pusriadi T, Hakim YP. 2018. Dampak kenaikan harga komoditas sembako terhadap tingkat inflasi di Indonesia. Di dalam: *Prosiding Seminar Nasional: Manajemen, Akuntansi, dan Perbankan*. 1(1):1048–1074.
- Desvina AP, Meijer IO. 2018. Penerapan model ARCH/GARCH untuk peramalan nilai tukar petani. *Jurnal Sains Matematika dan Statistika*. 4(1):43–54.
- Dickey DA, Fuller WA. 1979. Distribution of the estimators for the autoregressive time series with a unit root. *Journal of the American Statistical Association*. 74(366):427–431. doi:10.2307/2286348.
- Do ST, Reynolds AC. 2013. Theoretical connections between optimization algorithms based on an approximate gradient. *Comput Geosci*. 17:959–973. doi:10.1007/s10596-013-9368-9.
- Firdaus R, Mukhtar H, Awaluddin. 2023. Prediksi indeks harga produsen pertanian karet di Indonesia menggunakan metode LSTM. *Jurnal Fasilkom*. 13(1):1–6.
- Fitriadi MYG, Novianti T, Rifin A. 2023. Volatilitas harga bawang putih Indonesia. *Jurnal Ekonomi Pertanian dan Agribisnis*. 7(3):1201–1210. doi: 10.21776/ub.jepa.2023.007.03.25.
- Francq C, Zakoian JM. 2019. *GARCH Models: Structure, Statistical Inference and Financial Applications*. Chichester: John Wiley & Sons Ltd.
- Guo F, Liu P, Ren W, Cao N, Zhang C, Wen F, Zhou HM. 2019. Research on the relationship between garlic and young garlic shoot based on big data. *Tech Science Press* 58(2):363–378. doi:10.32604/cmc.2019.03794.
- Hadianto A, Amanda D, Asogiyan PK. 2019. Analisis pencapaian swasembada bawang putih Indonesia. *Sosial dan Ekonomi Pertanian*. 13(1):25–34.
- He K, Ji L, Wu CWD, Tso KFG. 2021. Using SARIMA-CNN-LSTM approach to forecast daily tourism demand. *Journal of Hospitality and Tourism Management* 49:25–33. doi:10.1016/j.jhtm.2021.08.022.
- Hochreiter S, Schmidhuber J. 1997. Long short-term memory. *Neural Computation* 9(8):1735–1780. doi:10.1162/neco.1997.9.8.1735.



- Jannah M. 2021. Kajian Metode Hybrid ARIMA-GARCH dan LSTM untuk Pendekatan Pemodelan Harga Beberapa Bahan Pokok [tesis]. Bogor: Institut Pertanian Bogor.
- Juanda B, Junaidi. 2011. *Ekonometrika Deret Waktu: Teori dan Aplikasi*. Bogor: IPB Press.
- Karlic B, Olgac AV. 2011. Performance analysis of various activation functions on generalized MLP architectures of neural network. *International Journal of Artificial Intelligent and Expert System* (IJAE). 1(4):111–122.
- [Kementan] Kementerian Pertanian. 2020. *Outlook Bawang Putih*. Jakarta: Pusat Data dan Sistem Informasi Pertanian.
- Kim HY, Won CH. 2018. Forecasting the volatility of stock price index: a hybrid model integrating LSTM with multiple GARCH-type models. *Expert Systems With Applications* 103:25–37. doi:10.1016/j.eswa.2018.03.002.
- Le N, Mannel B, Jarema M, Luong TT, Bui LK, Vy HQ, Schuh H. 2024. K-fold cross-validation: an effective hyperparameter tuning technique in machine learning on GNSS time series for movement forecast. Di dalam: *Recent Research on Geotechnical Engineering, Remote Sensing, Geophysics and Earthquake Seismology*. 377–382.
- Lestari I, Sumargo B, Ladayya F. 2022. Pemodelan ARIMA intervensi untuk meramalkan harga minyak mentah dunia. *Statistika*. 22(2):133–146.
- Lewis CD. 1982. *Industrial and Business Forecasting Methods*. London: Butterworth Scientific.
- Maharani NS, Angraini Y, Rahmawan MA, Putri OA, Kurniawan S, Rizki A, Ningsih WAL, Hidayatulloh NGT, Ratnasari AP. 2023. Aplikasi model ARIMA GARCH dalam peramalan data nilai tukar Rupiah terhadap Dolar tahun 2017–2022. *Jurnal Matematika, Sains, dan Teknologi*. 24(1):37–50.
- Mahjoub S, Chrifi-Alaoui L, Marhic B, Delahoche L. 2022. Predicting energy consumption using LSTM, multi-layer GRU and drop-GRU neural networks. *Sensors*. 22(11):1–20. doi:10.3390/S22114062.
- Masri F, Saepudin D, Adytia D. 2020. Forecasting of sea level time series using deep learning RNN, LSTM, and BiLSTM, case study in Jakarta Bay, Indonesia. Di dalam: *e-Proceeding of Engineering*. 7(2):8544–8551.
- Mawarni TS, Akmalia NA, Sevitri H. 2024. Analisis perkembangan harga bahan pangan pokok di pasar domestic Indonesia tahun 2023. *Jurnal Pendidikan Universal*. 1(2):87–97.
- Mualifah LNA. 2022. A Comparative Study of GARCH, LSTM, and Hybrid GARCH-LSTM Models for Analyzing the Dynamical Pattern of Stock Price Volatility [tesis]. Bogor: Institut Pertanian Bogor.
- Montgomery DC, Jennings CL, Kulahci M. 2015. *Introduction to Time Series Analysis and Forecasting*. Ed ke-2. New Jersey: John Wiley & Sons Ltd.
- Nayak SC, Misra BB, Behera HS. 2014. Impact of data normalization on stock index forecasting. *International Journal of Computer Information Systems and Industrial Management Applications*. 6:257–269.
- Nti IK, Nyarko-Boateng O, Aning J. 2021. Performance of machine learning algorithms with different k values in k-fold cross-validation. *I.J. Information Technology and Computer Science*. 6:61–71. doi:10.5815/ijitcs.2021.06.05.
- Okut H. 2021. Deep Learning for Subtyping and Prediction of Diseases: Long-Short Term Memory. London: IntechOpen.

- Pandey A, Jain A. 2017. Comparative analysis of KNN algorithm using various normalization techniques. I.J. Computer Network and Information Security 9(11):33-42. doi:10.5815/ijcnis.2017.11.04.
- Prasetyo T, Putri RA, Ramadhani D, Angraini Y, Notodiputro KA. 2024. Perbandingan kinerja metode ARIMA, multi-layer perceptron, dan random forest dalam peramalan harga logam mulia berjangka yang mengandung pencilan. Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK). 11(2):265-274. doi:10.25126/jtiik.2024117392.
- Raiaan MAK, Sakib S, Fahad NM, Mamun AA, Rahman MA, Shatabda S, Mukta MSH. 2024. A systematics review of hyperparameter optimization techniques in convolutional neural networks. Decision Analytics Journal. 11:1-32. doi: 10.1016/j.dajour.2024.100470.
- Riyadi AAF. 2024. Peramalan Curah Hujan Wilayah Kota Padang Menggunakan Metode *Long Short-Term Memory* [skripsi]. Bogor: Institut Pertanian Bogor.
- Sandra IK, Sahara, Krisnamurhi B, Novianti T. 2022. Dinamika harga bawang putih sebelum dan saat pandemi COVID-19 di Indonesia. Policy Brief. 4(1): 190-195.
- Sarah M, Sari RAP, Wati DR. 2023. Analisis peramalan jumlah produksi dan konsumsi bawang putih di Indonesia. Sharia Agribusiness Journal 3(2):107–124. doi:10.15408/saj.v3i2.35816.
- Sumaryanto. 2016. Analisis volatilitas harga eceran beberapa komoditas pangan utama dengna model ARCH/GARCH. Jurnal Agro Ekonomi 27(2):135-163. doi:10.21082/jae.v27n2.2009.
- Uskono, EKM. 2023. Aplikasi Metode ARIMA, LSTM, dan Hybrid ARIMA-LSTM pada Peramalan Harga Crude Palm Oil (CPO) Dunia [skripsi]. Bogor: Institut Pertanian Bogor.
- Wahyuningsih S, Goejantoro R, Siringoringo M, Saputra AR, Aminah S. 2019. Application seasonal autoregressive integrated moving average to forecast the number of East Kalimantan hotspots. Journal of Physics: Conference Series. 1351(1):1-5. doi:10.1088/1742-6596/1351/1/012085.
- Wang Y, Liu P, Zhu K, Liu L, Zhang Y, Xu G. 2022. A garlic-price prediction approach based on combined LSTM and GARCH-family model. Applied Science 12(22):1-23. doi:10.3390/app122211366.





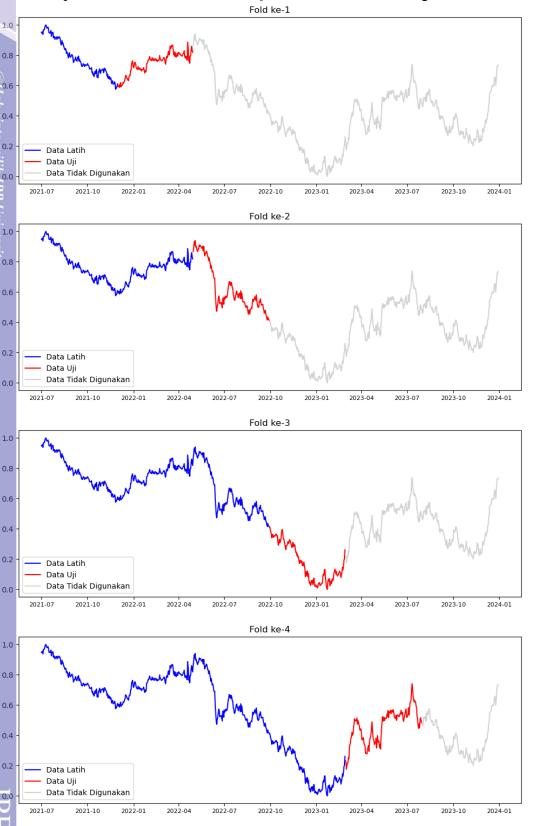
LAMPIRAN

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
b. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



Lampiran 1 Skenario time series k-fold cross validation dengan k = 5





Lampiran 1 Skenario time series k-fold cross validation dengan k = 5 (lanjutan) Fold ke-5



Lampiran 2 Hasil peramalan model hybrid GARCH-LSTM 120 hari ke depan

·		LSTM	Hybrid
01/03/2024	44.387,98	-6.856,57	37.531,41
02/03/2024	44.466,65	-6.889,59	37.577,07
03/03/2024	44.273,48	-6.922,03	37.351,46
04/03/2024	43.776,82	-6.953,92	36.822,91
05/03/2024	43.888,88	-6.985,26	36.903,62
06/03/2024	44.002,48	-7.016,07	36.986,42
07/03/2024	43.473,38	-7.046,35	36.427,02
08/03/2024	43.233,54	-7.076,13	36.157,41
09/03/2024	43.429,72	-7.105,41	36.324,31
10/03/2024	43.265,80	-7.134,20	36.131,60
11/03/2024	43.462,59	-7.162,52	36.300,08
12/03/2024	43.663,12	-7.190,36	36.472,76
13/03/2024	43.604,13	-7.217,76	36.386,38
14/03/2024	44.356,01	-7.244,70	37.111,31
15/03/2024	45.062,91	-7.271,21	37.791,70
16/03/2024	45.321,26	-7.297,29	38.023,97
17/03/2024	45.769,10	-7.322,95	38.446,15
18/03/2024	45.672,20	-7.348,20	38.324,00
19/03/2024	46.085,71	-7.373,05	38.712,65
20/03/2024	46.726,49	-7.397,51	39.328,98
21/03/2024	46.129,05	-7.421,58	38.707,47
22/03/2024	46.259,61	-7.445,28	38.814,33
23/03/2024	46.264,64	-7.468,60	38.796,03
24/03/2024	46.922,00	-7.491,56	39.430,44
25/03/2024	47.200,50	-7.514,17	39.686,33
26/03/2024	47.186,02	-7.536,42	39.649,60
27/03/2024	47.746,85	-7.558,34	40.188,51
28/03/2024	47.609,88	-7.579,92	40.029,96
29/03/2024	47.924,43	-7.601,17	40.323,25
30/03/2024	48.097,79	-7.622,10	40.475,68
31/03/2024	48.420,02	-7.642,72	40.777,30
01/04/2024	47.587,28	-7.663,02	39.924,25



Lampiran 2 Hasil peramalan model *hybrid* GARCH-LSTM 120 hari ke depan

@Hak cipta milik IPB Univer

Dilarang mengutip sebagian atau selurul Pengutipan hanya untuk kepentingan i

oan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilm Dan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilm Dan tidak merusikan kapantingan yang wajar IBR Hniversity

ngan yang wajar IPB University. Ngan yang wajar IPB University.

IPB University

(lanjutan)	•		
Tanggal	GARCH(1,1)	LSTM	Hybrid
02/04/2024	47.629,59	-7.683,02	39.946,57
03/04/2024	48.161,27	-7.702,73	40.458,54
04/04/2024	47.811,07	-7.722,14	40.088,94
05/04/2024	48.425,67	-7.741,26	40.684,42
06/04/2024	48.362,90	-7.760,10	40.602,80
07/04/2024	49.358,29	-7.778,66	41.579,63
08/04/2024	50.069,79	-7.796,95	42.272,84
09/04/2024	50.008,66	-7.814,98	42.193,68
10/04/2024	49.672,19	-7.832,74	41.839,44
11/04/2024	49.624,80	-7.850,25	41.774,55
12/04/2024	49.722,62	-7.867,50	41.855,11
13/04/2024	49.915,50	-7.884,51	42.030,99
14/04/2024	50.724,34	-7.901,27	42.823,07
15/04/2024	51.149,18	-7.917,79	43.231,39
16/04/2024	51.440,03	-7.934,08	43.505,95
17/04/2024	50.912,85	-7.950,14	42.962,71
18/04/2024	50.771,44	-7.965,96	42.805,48
19/04/2024	51.765,82	-7.981,57	43.784,25
20/04/2024	51.630,27	-7.996,96	43.633,31
21/04/2024	51.885,05	-8.012,13	43.872,93
22/04/2024	52.306,12	-8.027,09	44.279,03
23/04/2024	52.007,12	-8.041,84	43.965,28
24/04/2024	51.481,79	-8.056,39	43.425,41
25/04/2024	51.020,26	-8.070,73	42.949,53
26/04/2024	51.516,04	-8.084,88	43.431,16
27/04/2024	51.728,05	-8.098,83	43.629,22
28/04/2024	51.588,57	-8.112,59	43.475,97
29/04/2024	51.101,10	-8.126,17	42.974,93
30/04/2024	51.402,04	-8.139,56	43.262,48
01/05/2024	51.545,50	-8.152,80	43.392,71
02/05/2024	52.201,30	-8.165,90	44.035,40
03/05/2024	52.925,84	-8.178,89	44.746,95
04/05/2024	52.505,08	-8.191,76	44.313,32
05/05/2024	51.788,86	-8.204,52	43.584,34
06/05/2024	51.871,46	-8.217,16	43.654,30
07/05/2024	51.363,17	-8.229,68	43.133,49
08/05/2024	51.209,11	-8.242,08	42.967,03
09/05/2024	51.602,33	-8.254,36	43.347,97
10/05/2024	51.446,95	-8.266,52	43.180,43
11/05/2024	50.662,62	-8.278,56	42.384,06
12/05/2024	50.722,49	-8.290,48	42.432,02
13/05/2024	49.946,21	-8.302,27	41.643,94
14/05/2024	51.371,88	-8.313,95	43.057,93

Lampiran 2 Hasil peramalan model *hybrid* GARCH-LSTM 120 hari ke depan (*laniutan*)

(lanjutan)			
Tanggal	GARCH(1,1)	LSTM	Hybrid
15/05/2024	50.970,17	-8.325,50	42.644,67
16/05/2024	50.964,94	-8.336,94	42.628,00
17/05/2024	51.167,10	-8.348,25	42.818,84
18/05/2024	51.159,27	-8.359,45	42.799,82
19/05/2024	52.297,53	-8.370,53	43.927,00
20/05/2024	52.465,40	-8.381,50	44.083,90
21/05/2024	52.307,15	-8.392,35	43.914,80
22/05/2024	51.529,27	-8.403,08	43.126,19
23/05/2024	51.857,17	-8.413,70	43.443,47
24/05/2024	52.352,66	-8.424,21	43.928,45
25/05/2024	52.681,71	-8.434,61	44.247,11
26/05/2024	52.206,71	-8.444,90	43.761,81
27/05/2024	52.065,84	-8.455,08	43.610,76
28/05/2024	52.407,14	-8.465,15	43.941,99
29/05/2024	52.161,53	-8.475,12	43.686,41
30/05/2024	52.150,42	-8.484,98	43.665,43
31/05/2024	51.655,59	-8.494,74	43.160,85
01/06/2024	52.087,67	-8.504,40	43.583,27
02/06/2024	52.315,04	-8.513,96	43.801,08
03/06/2024	52.581,09	-8.523,42	44.057,67
04/06/2024	53.473,82	-8.532,78	44.941,04
05/06/2024	53.345,16	-8.542,05	44.803,11
06/06/2024	53.237,59	-8.551,22	44.686,37
07/06/2024	53.279,75	-8.560,29	44.719,45
08/06/2024	53.462,79	-8.569,28	44.893,51
09/06/2024	54.356,66	-8.578,17	45.778,49
10/06/2024	54.661,51	-8.586,98	46.074,54
11/06/2024	54.921,32	-8.595,69	46.325,63
12/06/2024	55.473,52	-8.604,32	46.869,20
13/06/2024	55.625,20	-8.612,87	47.012,33
14/06/2024	55.417,60	-8.621,33	46.796,27
15/06/2024	54.295,92	-8.629,70	45.666,22
16/06/2024	54.236,85	-8.638,00	45.598,86
17/06/2024	54.127,77	-8.646,22	45.481,56
18/06/2024	54.219,51	-8.654,35	45.565,16
19/06/2024	55.456,31	-8.662,42	46.793,90
20/06/2024	55.522,15	-8.670,39	46.851,76
21/06/2024	55.532,96	-8.678,26	46.854,70
22/06/2024	54.056,90	-8.686,02	45.370,88
23/06/2024	54.219,74	-8.693,67	45.526,07
24/06/2024	54.084,19	-8.701,22	45.382,97
25/06/2024	54.151,76	-8.708,66	45.443,10
26/06/2024	54.915,30	-8.716,00	46.199,30





Lampiran 2 Hasil peramalan model hybrid GARCH-LSTM 120 hari ke depan (laniutan)

Tanggal	GARCH(1,1)	LSTM	Hybrid
27/06/2024	54.260,96	-8.723,23	45.537,74
28/06/2024	53.854,66	-8.730,35	45.124,31



RIWAYAT HIDUP

Penulis dilahirkan di Kota Bekasi pada tanggal 10 Januari 2002 sebagai anak pertama dari pasangan Bapak Budi Harsono dan Ibu Siwi Aryantini. Penulis menempuh pendidikan tingkat sekolah menengah atas (SMA) di SMA Negeri 1 Kota Bekasi dan lulus pada tahun 2020. Pada tahun yang sama, penulis diterima sebagai mahasiswa program sarjana (S-1) di Program Studi Statistika dan Sains Data, Fakultas Matematika dan Ilmu Pengetahuan Alam, IPB University melalui jalur Seleksi Bersama Masuk Perguruan Tinggi (SBMPTN).

Selama mengikuti program S-1, penulis aktif dalam beberapa kegiatan organisasi, komunitas, dan kepanitiaan intrakampus. Dalam organisasi, penulis pernah menjabat sebagai anggota Departemen Beta Himpunan Mahasiswa Profesi Gamma Sigma Beta Statistika IPB pada periode 2022 dan Ketua Himpunan pada periode 2022/2023. Adapun dalam komunitas, penulis terlibat sebagai anggota Komunitas Pionir Muda IPB Batch 5 dan Komunitas Mahasiswa Nahdlatul Ulama Angkatan 57. Selain itu, penulis juga berpartisipasi dalam beberapa kepanitiaan, di antaranya sebagai anggota Divisi Pertandingan Pekan Olahraga Statistika 2021 dan Kepala Divisi Kompetisi Pesta Sains Nasional 2022. Selama berkuliah, penulis pernah berkesempatan untuk menjadi asisten praktikum dalam mata kuliah Teknik Penarikan Contoh pada semester genap tahun 2023 dan Analisis Regresi pada semester genap tahun 2024. Selama itu juga, penulis berkesempatan untuk mengikuti program Kampus Merdeka, yaitu menjalani program magang pada posisi Data Management di PT United Tractors Tbk. dan mengikuti studi independen dalam *learning path* Machine Learning pada program Bangkit 2024 Batch 1.